

Algoritmo de Deep Learning para predecir cáncer en imágenes histopatológicas

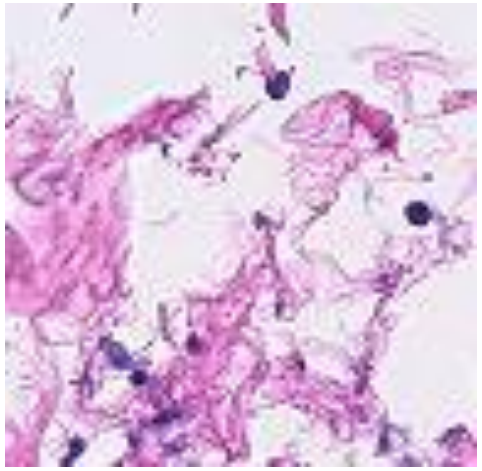
Integrantes:

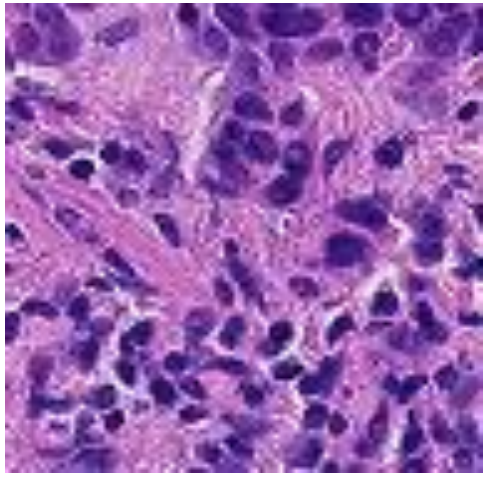
Eduardo Rodríguez

José Pinto

Martín López

1. Introducción





- Las imágenes histopatológicas son fotografías de tejidos tomadas con un microscopio después de haber sido teñidos.
- Se utilizan para examinar la microarquitectura de los tejidos y diagnosticar enfermedades como el cáncer.

El uso de algoritmos de Deep Learning en imágenes histopatológicas permite una automatización parcial del diagnóstico, ayudando a los patólogos a reducir la carga de trabajo y a aumentar la consistencia en los resultados.

Las redes neuronales convolucionales son particularmente efectivas para analizar imágenes histopatológicas porque pueden identificar patrones de textura, forma y estructura a diferentes escalas.

1.1 Problema y objetivo

El objetivo de este proyecto es evaluar y comparar el rendimiento de distintas arquitecturas de Deep Learning en la clasificación de imágenes histopatológicas de cáncer. Utilizando la base de datos PCAM (PatchCamelyon), se pretende identificar cuál de las arquitecturas consideradas ofrece la mejor precisión, eficiencia en términos de tiempo de cómputo y capacidad de generalización.

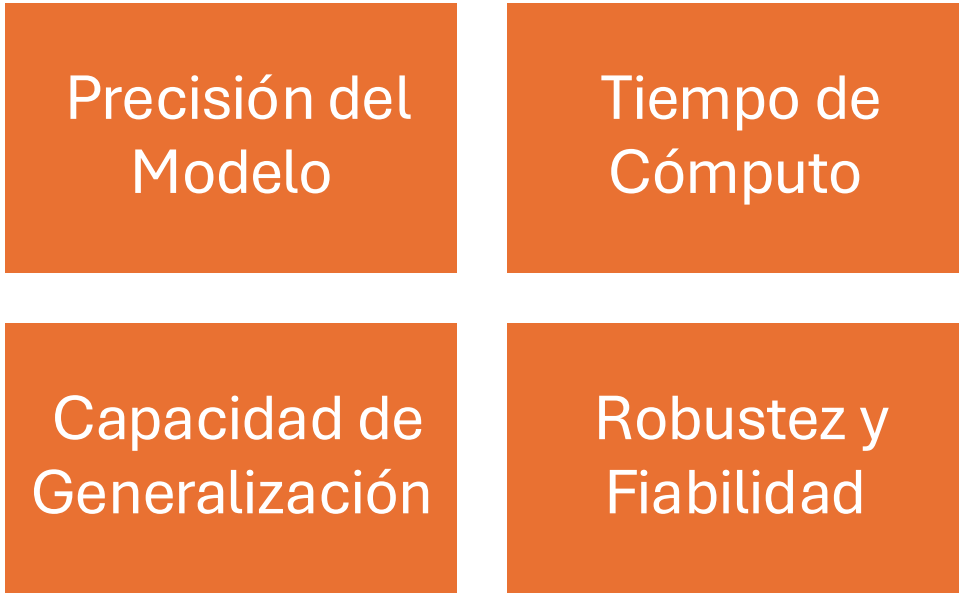
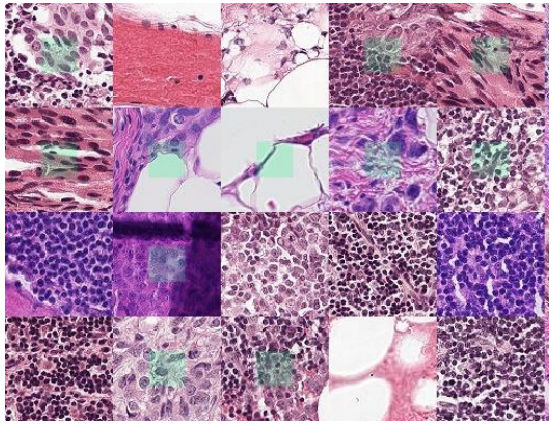
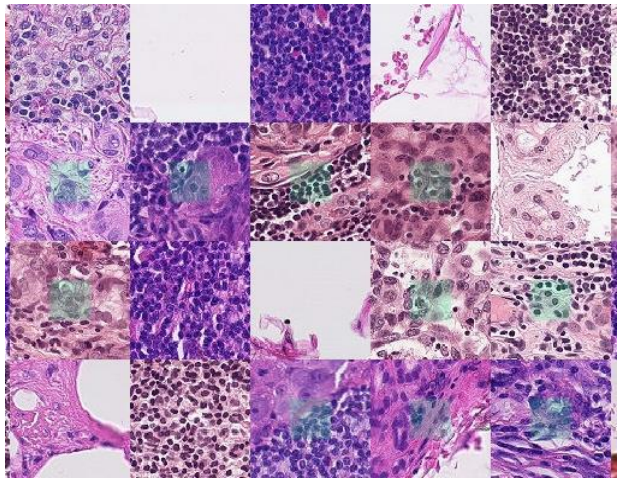


Figura 1: Aspectos a evaluar en los algoritmos de Deep Learning

2. Dataset: Histopathologic Cancer Detection (del Camelyon16 Challenge)

PCAM es un conjunto de datos de imágenes histológicas utilizado principalmente para la clasificación automatizada de imágenes en la investigación médica, específicamente en la detección de metástasis en ganglios linfáticos (Imágenes derivadas de biopsias digitalizadas de pacientes con cáncer de mama.).

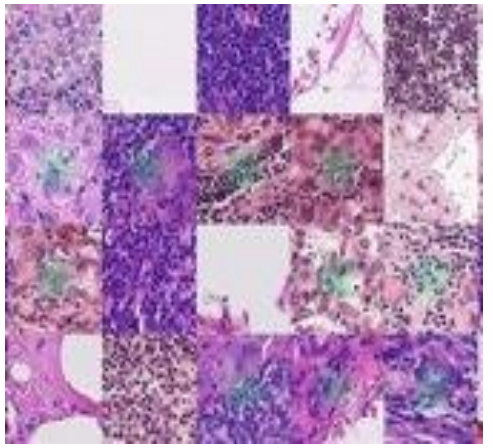




Origen y propósito

PCam se deriva del Camelyon16 Challenge, un desafío internacional para detectar metástasis en ganglios linfáticos a partir de imágenes de biopsias. Su objetivo es ofrecer un recurso accesible y estandarizado para investigar imágenes histológicas usando técnicas de aprendizaje automático y profundo.

2. Dataset: PatchCamelyon (PCAM)



PCAM contiene 327,680 imágenes de 32x32 píxeles, divididas equitativamente entre positivas (metástasis presente) y negativas (metástasis ausente). El equilibrio entre clases facilita el entrenamiento y evaluación de modelos de clasificación.

Los datos para este proyecto son una versión ligeramente modificada del conjunto de datos PatchCamelyon (PCam) que no contiene las imágenes duplicadas presentes en la versión original [1].

División

- **Entrenamiento:** 176,020 imágenes
- **Validación:** 44,005 imágenes
- **Prueba:** 44,005 imágenes

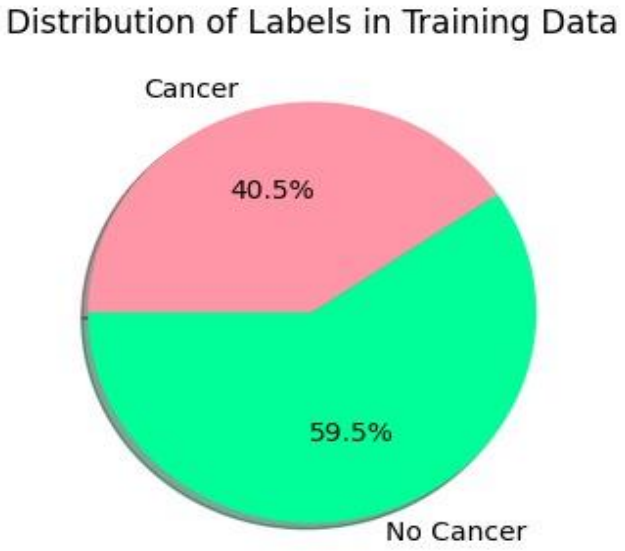


Figura 2: Proporción de muestras de tejido sano versus muestras con metástasis presente [Elaboración propia].

3. Estado del arte

DenseNet y RAdam para clasificación de metástasis

Este estudio se enfoca en la clasificación de cáncer metastásico utilizando la estructura de red profunda DenseNet junto con el algoritmo de optimización RAdam, mostrando una alta precisión en la identificación de cáncer metastásico en pequeños parches de imágenes histopatológicas de la base de datos PCAM. Este enfoque resalta la efectividad de las arquitecturas avanzadas de Deep Learning en la mejora de la precisión del diagnóstico automático.

Se comparó el rendimiento de Resnet34, Resnet50, Vgg19 y Densenet169 implementado [2].

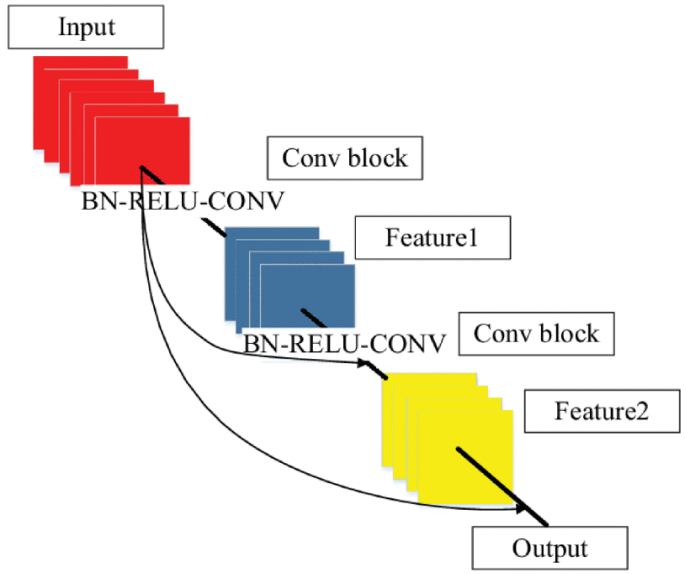


Figura 3: Arquitectura del modelo DenseNet implementado en el artículo [2].

Models	Auc Roc Score	Accuracy
Resnet34	0.9633	0.975
Resnet50	0.9642	0.976
Vgg19	0.9473	0.965
Densenet169	0.965	0.980

Figura 4: Comparación de AUC y Accuracy de los modelos implementados [2].

3. Estado del arte

Comparación de métodos de preprocesamiento e implementación de modelos de Deep Learning

Un estudio comparativo evaluó cinco modelos de deep learning diferentes (incluyendo CNNs y modelos basados en transfer learning) para la clasificación de imágenes de cáncer de mama. Los resultados indican que la elección del modelo de deep learning tiene un impacto significativo en la precisión, mientras que los métodos de preprocesamiento de imágenes no afectan significativamente el rendimiento del sistema [3].

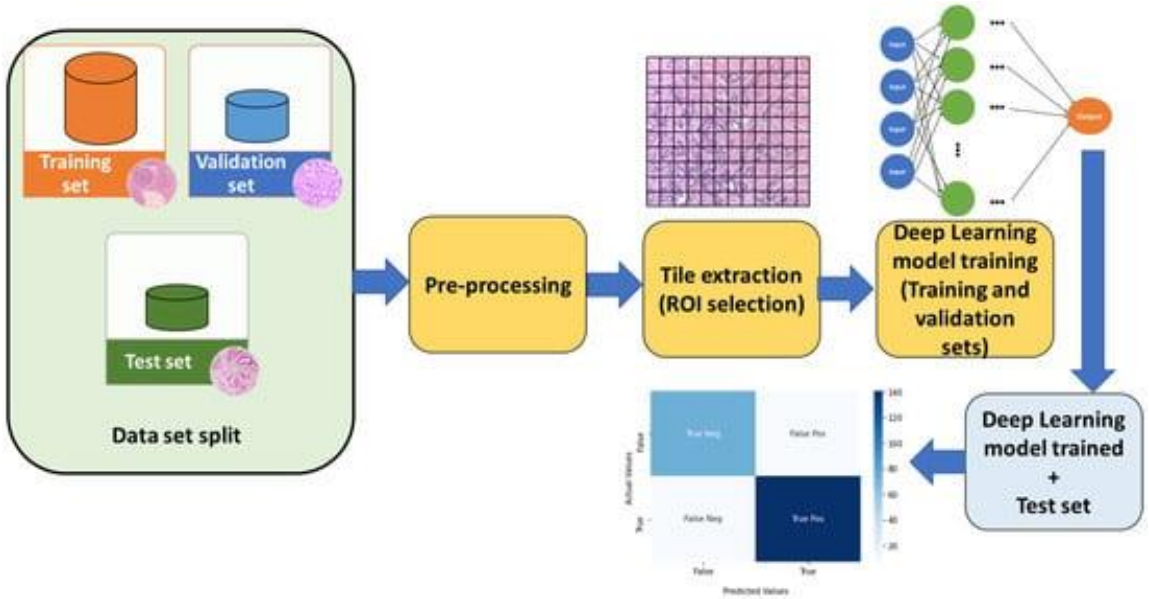


Figura 5: Metodología aplicada en el artículo [3]

3. Estado del arte

Metrics	Models	Raw	Blur	CLAHE	Contour	Detail	Edge Enhance	Edge Enhance More	FHE	HE	Sharpen
Accuracy	VGG16	86.93 ± 0.17	85.69 ± 0.23	**86.22 ± 0.35**	**85.62 ± 0.30**	86.85 ± 0.22	**86.49 ± 0.35**	86.22 ± 0.45	**86.48 ± 0.37**	**85.81 ± 0.16**	86.85 ± 0.27
	VGG19	86.84 ± 0.15	85.73 ± 0.12	86.24 ± 0.25	85.80 ± 0.33	86.55 ± 0.28	86.38 ± 0.30	**86.25 ± 0.31**	86.39 ± 0.17	85.63 ± 0.34	86.71 ± 0.23
	ResNet50	**86.98 ± 0.16**	**86.00 ± 0.05**	85.89 ± 0.17	85.39 ± 0.33	**86.85 ± 0.10**	86.31 ± 0.22	85.74 ± 0.04	86.39 ± 0.07	85.25 ± 0.09	**86.95 ± 0.14**
	MobilNet	86.44 ± 0.08	85.53 ± 0.58	85.43 ± 0.25	84.37 ± 0.27	86.16 ± 0.15	86.09 ± 0.40	85.55 ± 0.05	85.84 ± 0.17	84.93 ± 0.09	86.38 ± 0.08
	DenseNet121	85.62 ± 0.12	84.69 ± 0.19	84.66 ± 0.18	83.88 ± 0.20	85.35 ± 0.36	84.89 ± 0.13	84.43 ± 0.01	85.11 ± 0.12	84.23 ± 0.23	85.38 ± 0.20
Precission	VGG16	87.39 ± 0.42	86.34 ± 0.82	**86.89 ± 1.23**	85.20 ± 0.50	86.23 ± 1.23	85.66 ± 1.62	85.80 ± 1.45	**86.34 ± 0.46**	**86.35 ± 1.21**	86.19 ± 0.98
	VGG19	86.24 ± 1.57	**86.35 ± 0.57**	84.94 ± 1.79	**85.78 ± 0.40**	84.54 ± 0.97	**86.50 ± 0.40**	**86.35 ± 0.71**	85.41 ± 1.20	83.98 ± 1.36	85.35 ± 1.05
	ResNet50	86.21 ± 0.46	85.67 ± 0.56	85.43 ± 0.17	84.32 ± 0.65	**86.42 ± 0.23**	85.84 ± 0.34	85.12 ± 0.17	86.03 ± 0.48	84.99 ± 0.16	**86.37 ± 0.23**
	MobilNet	**86.51 ± 0.40**	84.24 ± 1.68	84.17 ± 2.05	83.19 ± 1.91	85.04 ± 1.89	86.09 ± 0.12	84.26 ± 0.19	84.79 ± 1.28	84.87 ± 1.32	84.56 ± 0.72
	DenseNet121	85.24 ± 0.35	84.25 ± 0.33	83.85 ± 0.52	83.20 ± 0.30	85.16 ± 0.42	84.43 ± 0.10	83.90 ± 0.15	84.85 ± 0.10	83.68 ± 0.16	85.20 ± 0.35
Recall	VGG16	86.32 ± 0.38	84.82 ± 0.92	85.37 ± 2.22	86.23 ± 1.02	87.76 ± 1.21	**87.75 ± 1.50**	86.86 ± 1.33	86.68 ± 0.97	85.13 ± 1.84	87.83 ± 0.90
	VGG19	87.76 ± 2.52	84.90 ± 1.00	**88.21 ± 2.28**	85.85 ± 0.91	**89.49 ± 0.78**	86.22 ± 0.98	86.13 ± 0.64	**87.81 ± 1.43**	**88.14 ± 1.63**	88.71 ± 1.06
	ResNet50	**88.04 ± 0.35**	86.48 ± 0.77	86.54 ± 0.47	**86.96 ± 0.20**	87.44 ± 0.43	86.96 ± 0.08	86.61 ± 0.28	86.90 ± 0.81	85.61 ± 0.15	87.78 ± 0.30
	MobilNet	86.34 ± 0.36	**87.50 ± 1.20**	87.44 ± 2.48	86.30 ± 2.65	87.89 ± 2.63	85.87 ± 0.53	**87.43 ± 0.38**	87.43 ± 2.18	85.08 ± 2.08	**89.06 ± 0.98**
	DenseNet121	86.43 ± 0.64	85.35 ± 0.32	85.86 ± 0.43	84.91 ± 0.12	85.62 ± 0.59	85.55 ± 0.39	85.21 ± 0.22	85.48 ± 0.29	85.05 ± 0.43	85.66 ± 0.20
AUC	VGG16	**94.15 ± 0.14**	93.24 ± 0.16	93.63 ± 0.10	92.75 ± 0.26	93.93 ± 0.26	**93.66 ± 0.22**	93.32 ± 0.23	93.60 ± 0.32	**93.12 ± 0.06**	93.86 ± 0.32
	VGG19	94.13 ± 0.06	**94.29 ± 1.63**	93.63 ± 0.04	**92.88 ± 0.39**	**93.96 ± 0.18**	93.61 ± 0.27	**93.34 ± 0.37**	**93.77 ± 0.04**	93.07 ± 0.19	**94.02 ± 0.12**
	ResNet50	93.93 ± 0.15	93.29 ± 0.08	**93.98 ± 1.64**	92.47 ± 0.35	93.87 ± 0.22	93.53 ± 0.07	92.93 ± 0.04	93.41 ± 0.21	92.48 ± 0.16	93.86 ± 0.03
	MobilNet	93.35 ± 0.16	92.57 ± 0.63	92.38 ± 0.38	91.57 ± 0.47	93.32 ± 0.38	92.77 ± 0.15	92.41 ± 0.01	92.91 ± 0.15	92.09 ± 0.12	93.50 ± 0.07
	DenseNet121	92.92 ± 0.09	92.16 ± 0.08	92.24 ± 0.07	91.22 ± 0.22	92.60 ± 0.18	92.33 ± 0.07	91.89 ± 0.07	92.51 ± 0.03	91.87 ± 0.12	92.58 ± 0.16

Figura 6: Análisis comparativo de los modelos frente a distintos preprocesamientos [3]

3. Estado del arte

Uso de modelos híbridos CNN y RNN

Este trabajo propone un método híbrido que combina redes convolucionales (CNN) y redes recurrentes (RNN) para mejorar la clasificación de imágenes histopatológicas de cáncer de mama. Este enfoque combina las ventajas de ambos tipos de redes para capturar características espaciales y temporales, lo cual es crucial para un diagnóstico preciso [4].

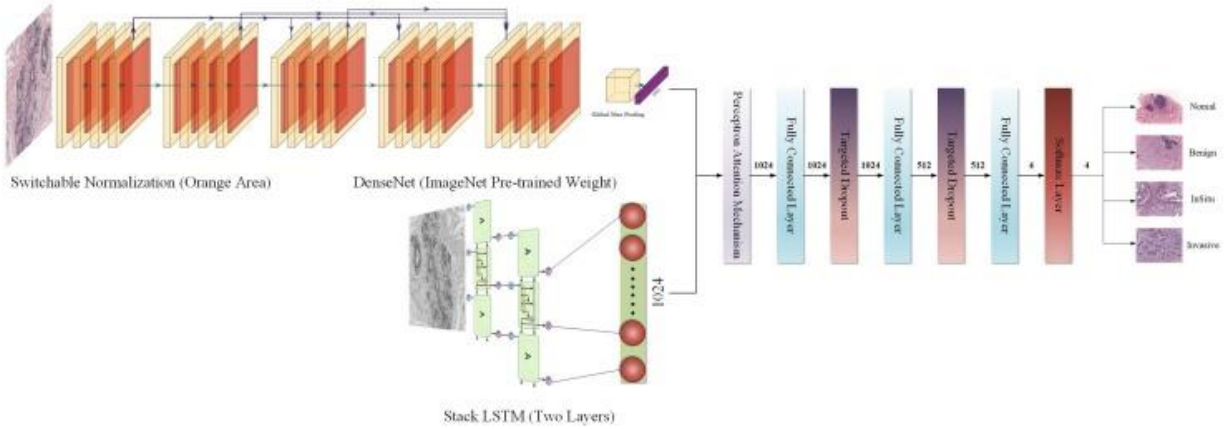


Figura 7: Arquitectura del modelo [4].

Models	1-Fold	2-Fold	3-Fold	4-Fold	5-Fold	Accuracy on Test Set (Best)
CNN (DenseNet121)	0.7312	0.6273	0.5973	0.7645	0.6795	0.73
CNN (DenseNet121) + TD	0.7593	0.7485	0.7062	0.7993	0.838	0.82
CNN (DenseNet121) + SN	0.868	0.8682	0.78	0.8635	0.8735	0.86
CNN (DenseNet121) + RNN (LSTM)	0.8397	0.7688	0.8128	0.8662	0.8482	0.82
CNN (DenseNet121) + SN + RNN (LSTM) + TD	0.8542	0.8495	0.8495	0.8355	0.811	**0.89**
CNN (DenseNet121) + SN + RNN (LSTM) + Attention + TD	0.8515	0.847	0.8148	0.8647	0.8323	**0.89**
CNN (Xception) + SN + RNN (LSTM) + Attention + TD	0.8113	0.8487	0.8143	0.863	0.8468	0.86
CNN (Inception ResNet V2) + SN + RNN (LSTM) + Attention + TD	0.8113	0.8487	0.8143	0.863	0.8468	0.86
CNN (DenseNet121 + Xception + Inception ResNet V2) + TD + SN + RNN (LSTM)+ Attention (Ensemble)						0.88
CNN (DenseNet121 + DenseNet169) + TD + SN + RNN (LSTM) + Attention (Ensemble)						**0.92**
ResNet + G-loss [22]						**0.91**

Figura 8: Comparación de distintas arquitecturas. Podemos notar como la combinación de CNN + RNN logra mejores resultados [4].

3. Estado del arte

Evaluación de distintos algoritmos Transfer learning

En este estudio se utilizó transfer learning con distintos modelos y distintos dataset de imágenes histopatológicas. Los modelos evaluados fueron: AlexNet, ResNet, VGG16, VGG19, Inception V3, SqueezeNet, DenTnet.

Models	ACC of various datasets				GMN of ACC	
	BreaKHis [33]	Malaria [191]	SkinCancer [193]	CovidXray [192]	Success	Failure
AlexNet [81]	0.9268	0.9738	0.8714	0.8526	0.9049	0.0951
ResNet [75]	0.9857	0.9832	0.9045	0.8990	0.9422	0.0578
VGG16 [98]	0.9785	0.9806	0.8501	0.8576	0.9145	0.0855
VGG19 [98]	0.9785	0.9811	0.8512	0.9279	0.9328	0.0672
Inception V3 [88]	0.9784	0.9879	0.8587	0.8998	0.9296	0.0704
SqueezeNet [184]	0.9756	0.9498	0.8288	0.8016	0.8858	0.1142
DenTnet [ours]	0.9928	0.9865	0.9157	0.8942	0.9463	0.0537

Figura 9: Comparación de Accuracy para los distintos modelos [5].

Models	F1S of various datasets				GMN of F1S	
	BreaKHis [33]	Malaria [191]	SkinCancer [193]	CovidXray [192]	Success	Failure
AlexNet [81]	0.9479	0.9734	0.8770	0.8811	0.9189	0.0811
ResNet [75]	0.9896	0.9830	0.9129	0.9147	0.9494	0.0506
VGG16 [98]	0.9843	0.9803	0.8634	0.9143	0.9342	0.0658
VGG19 [98]	0.9845	0.9809	0.8546	0.9448	0.9397	0.0603
Inception V3 [88]	0.9844	0.9724	0.8693	0.9077	0.9322	0.0678
SqueezeNet [184]	0.9823	0.9479	0.8336	0.8571	0.9031	0.0969
DenTnet [ours]	0.9948	0.9864	0.9233	0.9108	0.9531	0.0469

Figura 10: Comparación de F1-Score para los modelos [5].

Models	AUC of various datasets				GMN of AUC	
	BreaKHis [33]	Malaria [191]	SkinCancer [193]	CovidXray [192]	Success	Failure
AlexNet [81]	0.90	0.97	0.87	0.85	0.8964	0.1036
ResNet [75]	0.99	0.98	0.90	0.91	0.9441	0.0559
VGG16 [98]	0.98	0.98	0.86	0.85	0.9154	0.0846
VGG19 [98]	0.97	0.98	0.85	0.91	0.9260	0.0740
Inception V3 [88]	0.97	0.97	0.89	0.87	0.9239	0.0761
SqueezeNet [184]	0.97	0.95	0.83	0.75	0.8703	0.1297
DenTnet [ours]	0.99	0.99	0.91	0.90	0.9465	0.0535

Figura 11: Comparación de AUC para los modelos [5].

4. Métodos y modelos

Analizaremos el rendimiento de distintas arquitecturas de Deep Learning:

- Resnet18
- SqueezeNet1.0
- CNN
- VisualTransformers

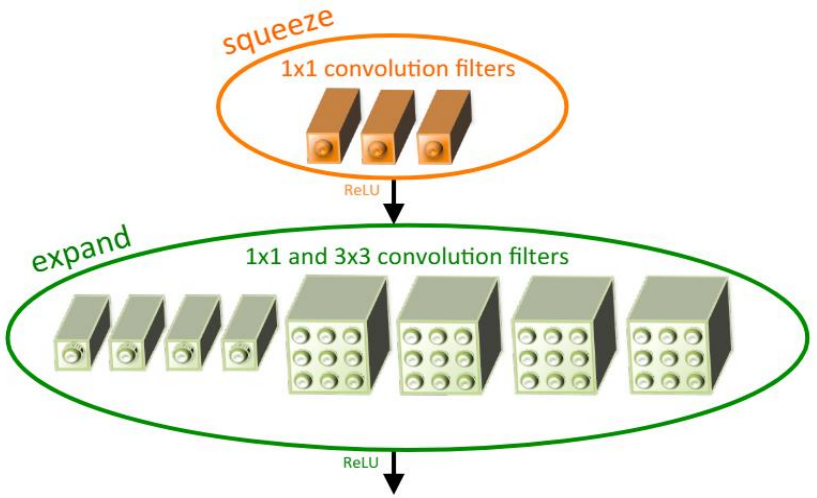


Figura 12: Capa fire de una SqueezeNet.

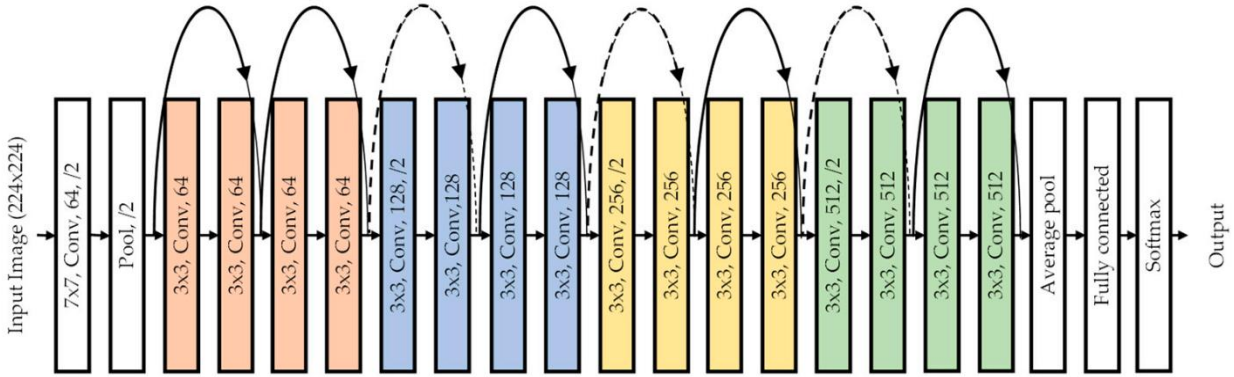


Figura 13: Arquitectura del modelo ResNet18.

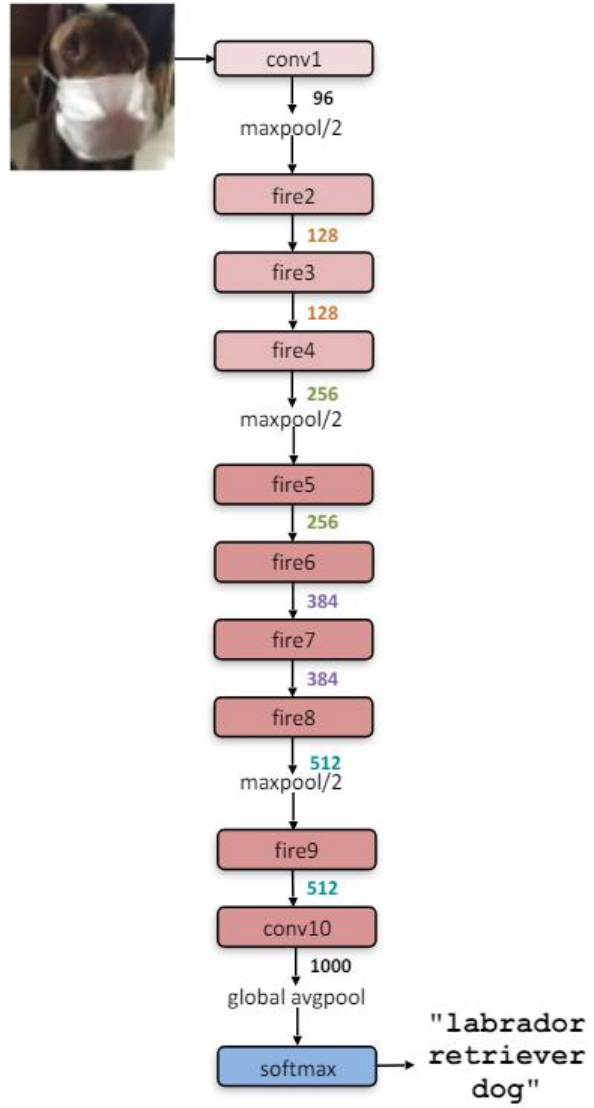


Figura 14: Arquitectura del modelo SqueezeNet.

4. Métodos y modelos

También intentaremos implementar en modelo como el que detallamos en la revisión de la literatura, que combinaba CNN y RNN.

Los **visions Transformers** utilizan Transformer para clasificar imágenes. Estos modelos han logrado unos rendimientos muy buenos en distintas bases de datos, sin embargo, son más costosos computacionalmente que las CNN.

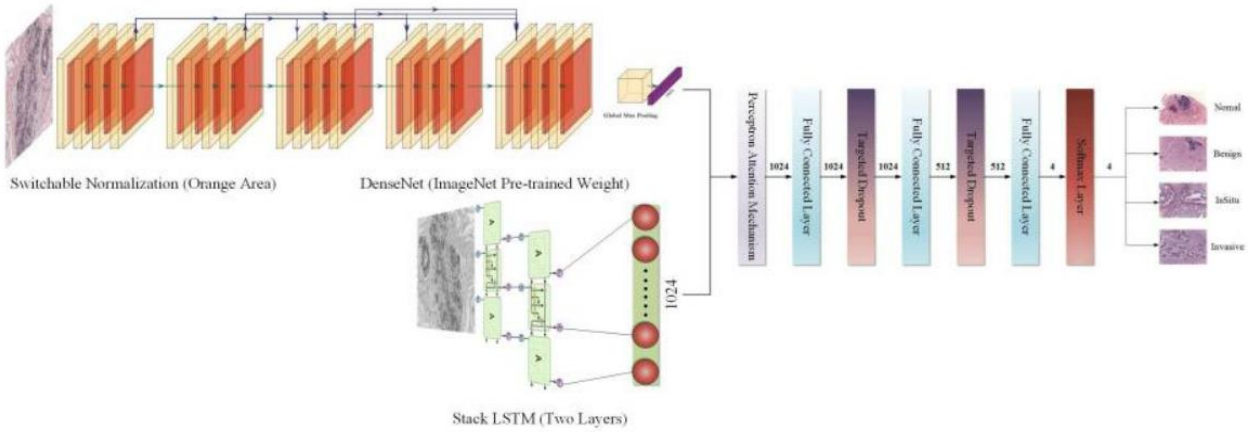


Figura 15: Ejemplo de arquitectura que combina CNN y RNN.

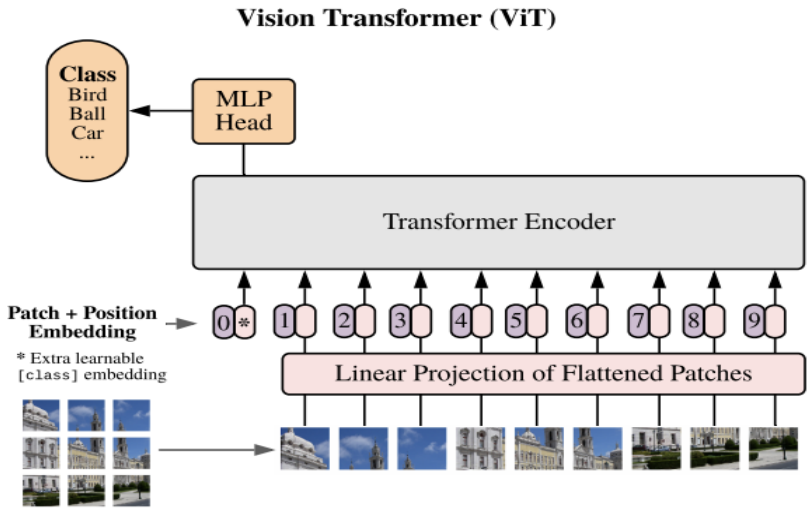


Figura 16: Arquitectura del modelo Vision Transformer (VIT).

4. Métodos y modelos

Además de las arquitecturas, también implementaremos otros métodos:

1. **Validación cruzada:** aplicaremos validación cruzada para obtener unos mejores resultados.

2. **Regularización:** Probaremos distintos métodos, como L1, L2, Dropout, Early Stopping, Batch Normalization, Weight Decay, Gradient Clipping.

3. **Aumento de datos:** Aunque tenemos un conjunto de datos relativamente grande, es necesario aplicar un aumento de datos para mejorar rendimiento, evitar sobreajuste, etc.

5. Resultados preliminares – Resnet-18

Hiperparámetro	Valor
Batch Size	64
Optimizador	Adams
Learning Rate	0.001
Función de perdida	Entropía Cruzada
Épocas	8

Tabla I: Hiperparámetros del modelo Resnet-18 implementado

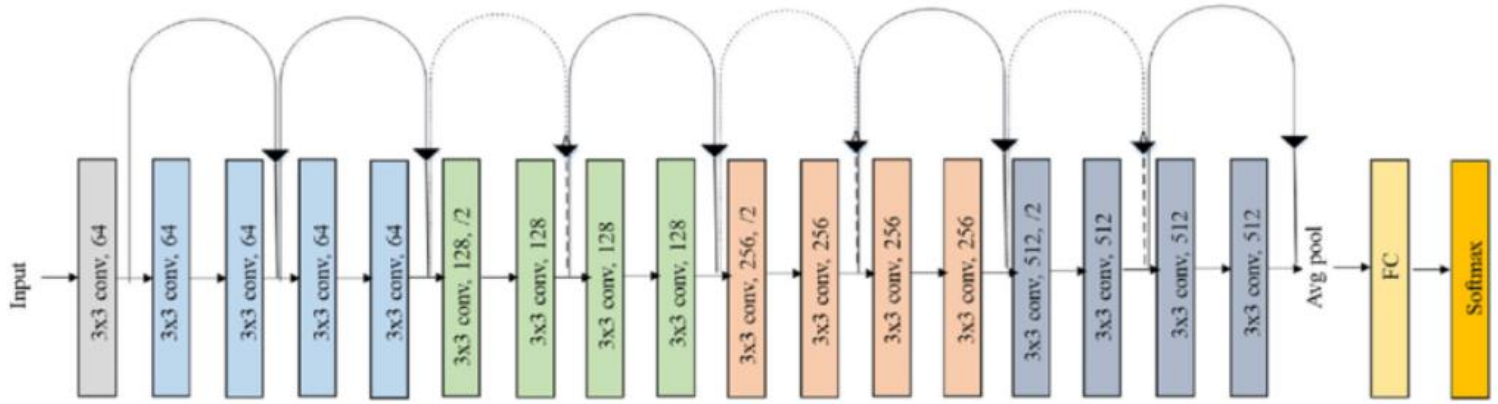


Figura 17: Arquitectura del modelo Resnet-18 de Pytorch

5. Resultados preliminares – Resnet-18

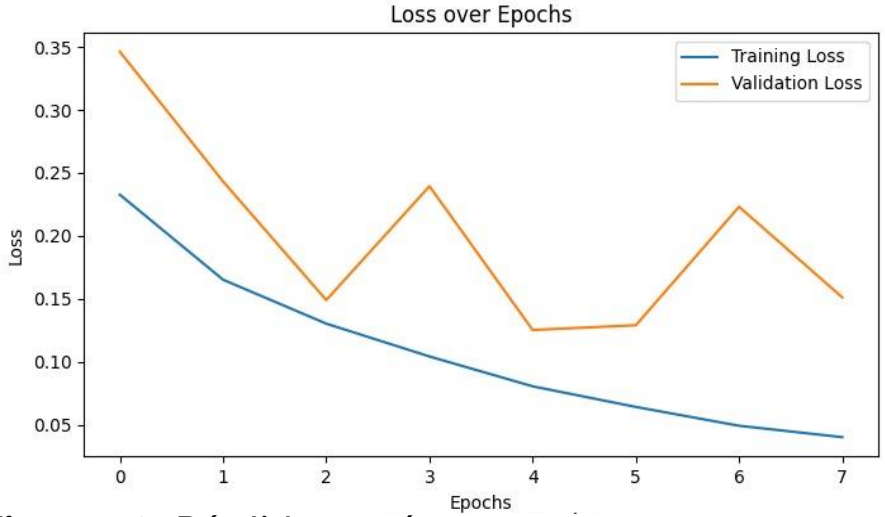


Figura 18: Pérdida por época

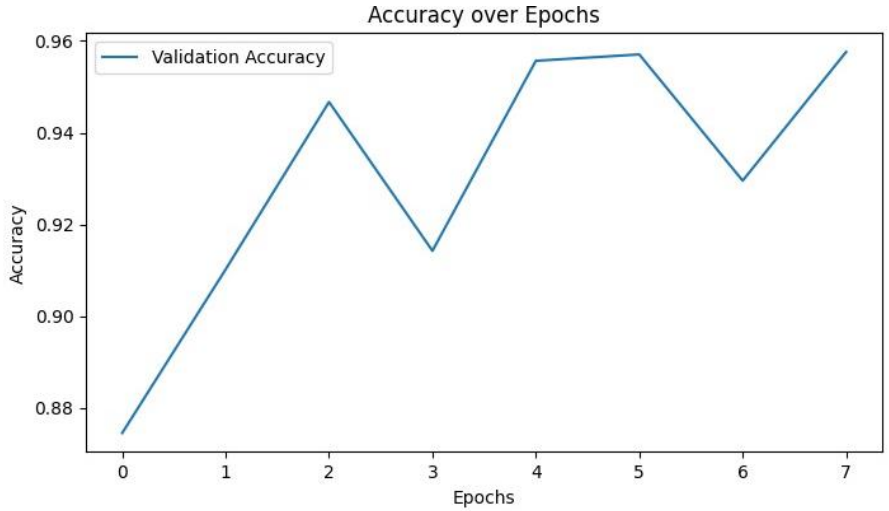


Figura 20: Accuracy por época

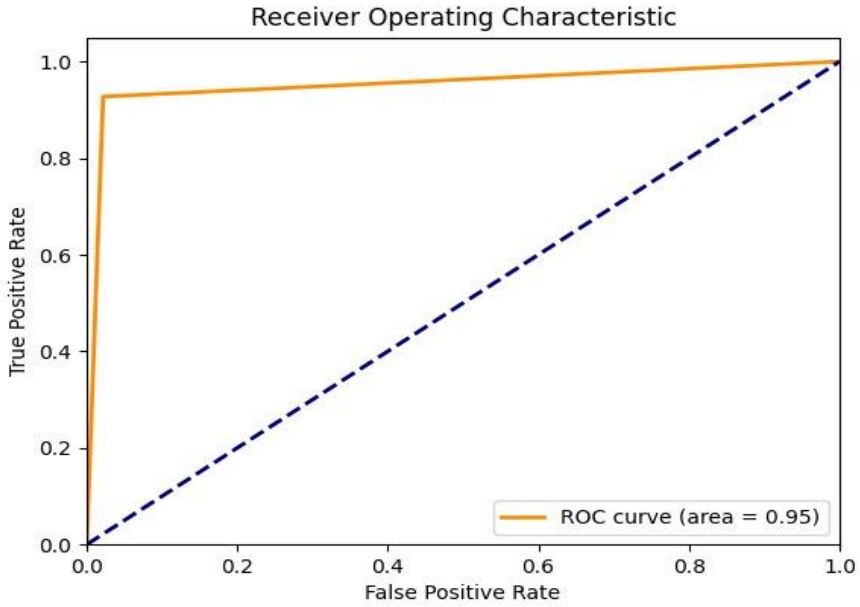


Figura 19: Curva ROC

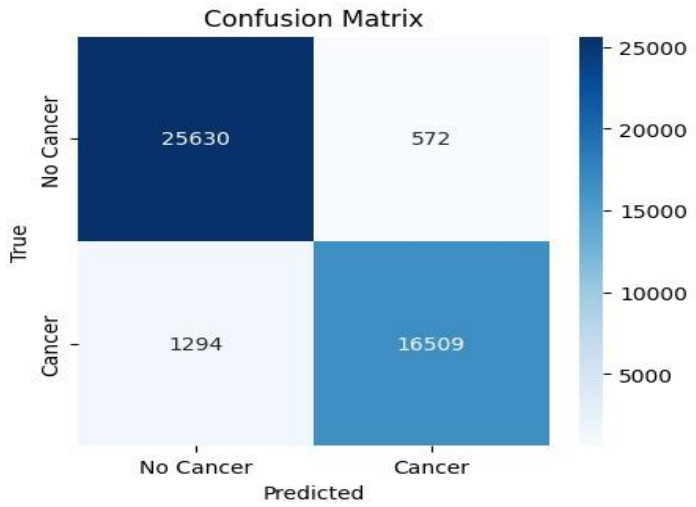


Figura 21: Matriz de confusión

6. Resultados preliminares – SqueezeNet 1.0

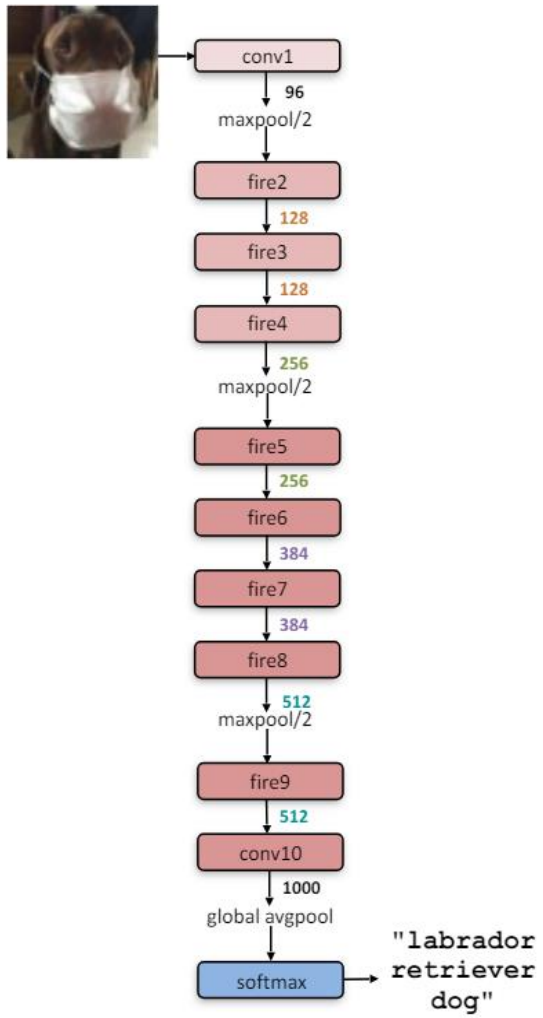


Figura 22: Arquitectura del modelo SqueezeNet

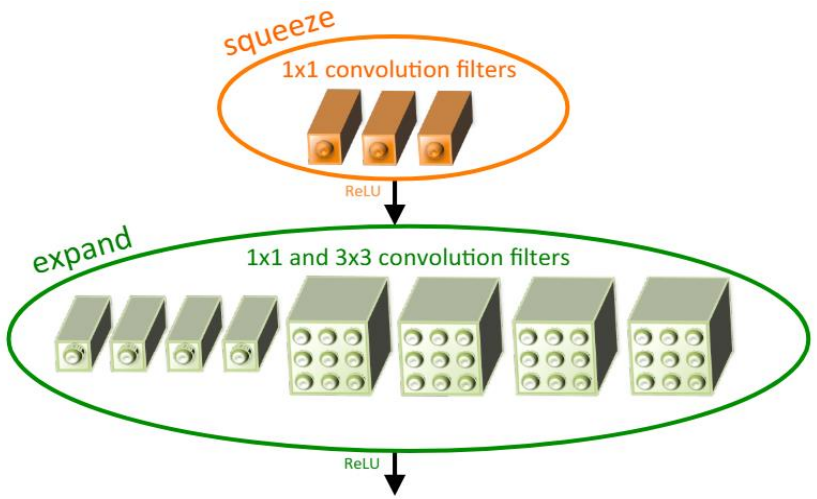


Figura 23: Capa fire de una SqueezeNet

Hiperparámetro	Valor
Batch Size	32
Optimizador	Adams
Learning Rate	0.0001
Función de perdida	Entropía Cruzada
Épocas	16

Tabla II: Hiperparámetros del modelo SqueezeNet 1.0

6. Resultados preliminares – SqueezeNet 1.0

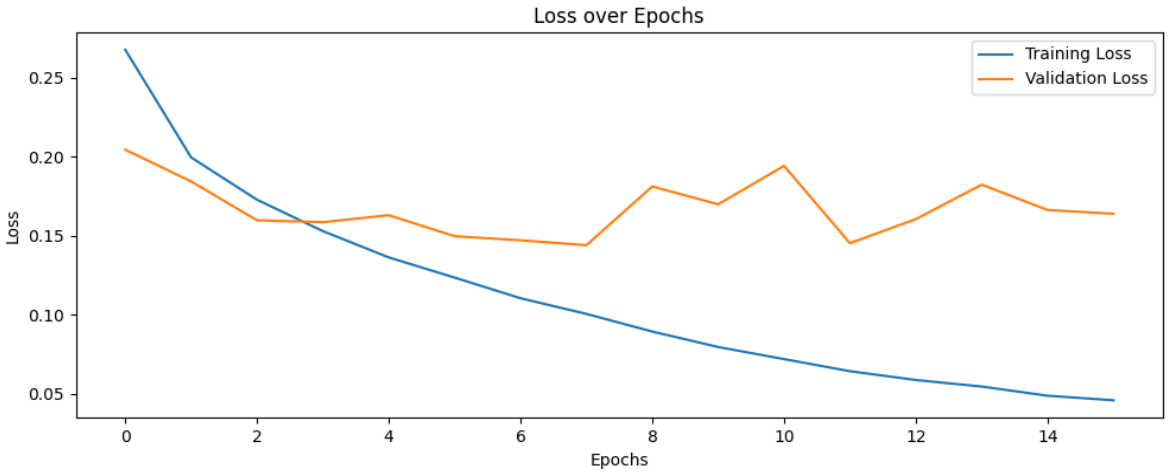


Figura 24: Pérdida por época

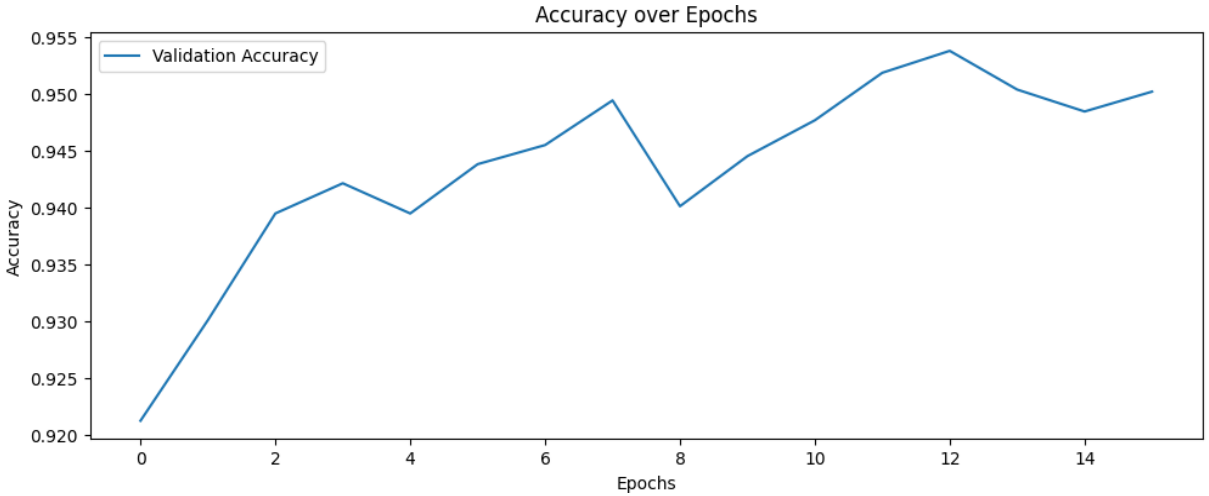


Figura 26: Accuracy por época

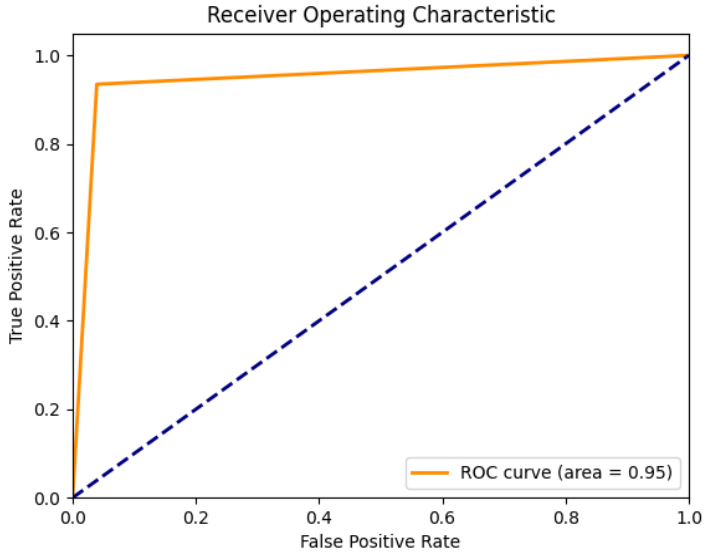


Figura 25: Curva ROC

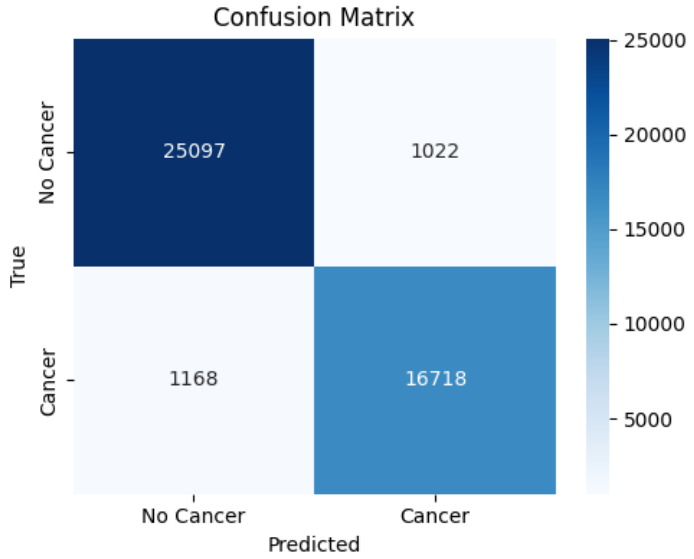


Figura 27: Matriz de confusión

Referencias

- [1] W. Cukierski, "Histopathologic Cancer Detection," Kaggle, 2018. [Online]. Available: https://kaggle.com/competitions/histopathologic-cancer-detection. [Accessed: May, 2024].
- [2] G. Qiu, X. Yu, B. Sun, Y. Wang, and L. Zhang, "Metastatic cancer image classification based on deep learning method," in 2021 IEEE International Conference on Consumer Electronics and Computer Engineering (ICCECE), Jan. 2021, pp. 658-661.
- [3] Murcia-Gomez, D., Rojas-Valenzuela, I., & Valenzuela, O. (2022). Impact of image preprocessing methods and deep learning models for classifying histopathological breast cancer images. Applied Sciences, 12(22), 11375.
- [4] Yao, H., Zhang, X., Zhou, X., & Liu, S. (2019). Parallel structure deep neural network using CNN and RNN with an attention mechanism for breast cancer histology image classification. Cancers (Basel) 11 (12): 1901.
- [5] Wakili, M. A., Shehu, H. A., Sharif, M. H., Sharif, M. H. U., Umar, A., Kusetogullari, H., & Uyaver, S. (2022). Classification of breast cancer histopathological images using DenseNet and transfer learning. Computational Intelligence and Neuroscience, 2022.